

# Prova Inferência

Ivan Cunha Vieira

2025-01-29

## Questão 2.

1.

Espaço paramétrico:  $\Theta = (0, \infty)$ .

Suporte de X:  $A(x) = (0, \theta)$ .

2.

Para mostrar que  $\hat{\theta}_1$  é não viciado para  $\theta$ , devemos utilizar a natureza da distribuição de X, tal que  $X \sim U(0, \theta)$  e, portanto,  $E[X] = \theta$  e  $Var[X] = \frac{\theta^2}{12}$ . Seguindo para  $\hat{\theta}_1$ , temos:

$$\hat{\theta}_1 = 2\bar{X} = \sum_{i=1}^n \frac{2X_i}{n} \rightarrow E[\hat{\theta}_1] = \frac{2}{n} E[\sum_{i=1}^n X_i] = \frac{2n}{n} E[X] = E[X] = \theta.$$

Assim,  $\hat{\theta}_1$  é não viciado, pois:  $B(\hat{\theta}_1) = E[\hat{\theta}_1] - \theta = 0$

Para mostrar que  $\hat{\theta}_2$  é não viciado para  $\theta$ , devemos utilizar de probabilidade, tal que  $P(X_{(n)} \leq x) = P(X_1 \leq x, \dots, X_n \leq x) = P(X \leq x)^n$ . Como  $X \sim U(0, \theta) \rightarrow P(X \leq x)^n = (\frac{x}{\theta})^n$ .

Dessa forma, encontramos a função de distribuição acumulada, que nos leva à função de densidade de probabilidade, tal que f.d.p. =  $\frac{nx^{n-1}}{\theta^n}$ . Assim,  $E[X_{(n)}] = \frac{n}{\theta^n} \int_0^\theta x.x^{n-1}dx = \frac{n\theta^{n+1}}{\theta^n(n+1)} = \frac{n\theta}{n+1}$ .

Agora,  $\hat{\theta}_2 = \frac{n+1}{n}X_{(n)} \rightarrow E[\hat{\theta}_2] = \frac{n+1}{n}E[X_{(n)}] = \theta$ .

Com isso, encontramos que  $\hat{\theta}_2$  é não viciado, pois:  $B(\hat{\theta}_2) = E[\hat{\theta}_2] - \theta = 0$

3.

Calculando os EQMs de  $\hat{\theta}_1$  e  $\hat{\theta}_2$ :

$$Var(\hat{\theta}_1) = Var(\frac{2\sum_{i=1}^n X_i}{n}) = \frac{4n}{n^2} Var(X) = \frac{4\theta^2}{12n} = \frac{\theta^2}{3n}.$$

Como  $\hat{\theta}_1$  é não viciado,  $EQM(\hat{\theta}_1) = Var(\hat{\theta}_1) = \frac{\theta^2}{3n}$ .

$$Var(\hat{\theta}_2) = \frac{(n+1)^2}{n^2} Var(X_{(n)}) \quad E[\hat{\theta}_2^2] = \frac{n}{\theta^n} \int_0^\theta x^2.x^{n-1}dx = \frac{n\theta^{n+2}}{\theta^n(n+2)} = \frac{n\theta^2}{n+2}.$$

$$\text{Agora, } Var(X_{(n)}) = \frac{n\theta^2}{n+2} - (\frac{n\theta}{n+1})^2 = \frac{n\theta^2[(n+1)^2 - n(n+2)]}{(n+2)(n+1)^2} = \frac{n\theta^2}{(n+2)(n+1)^2}.$$

Dessa forma,  $Var(\hat{\theta}_2) = \frac{(n+1)^2}{n^2} Var(X_{(n)}) = \frac{\theta^2}{n(n+2)}$ .

Como  $\hat{\theta}_2$  é não viciado,  $EQM(\hat{\theta}_2) = Var(\hat{\theta}_2) = \frac{\theta^2}{n(n+2)}$ .

E, portanto, encontramos que para  $n > 1 \rightarrow EQM(\hat{\theta}_2) < EQM(\hat{\theta}_1)$ , o que faz de  $\hat{\theta}_2$  mais eficiente.

#### 4.

Um estimador consistente possui as seguintes característica:  $\lim_{n \rightarrow \infty} E[\theta] = \theta$  e  $\lim_{n \rightarrow \infty} Var[\theta] = 0$ . Para os estimadores do problema, temos que:

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_1] = \lim_{n \rightarrow \infty} \theta = \theta \text{ e } \lim_{n \rightarrow \infty} Var[\hat{\theta}_1] = \lim_{n \rightarrow \infty} \frac{\theta^2}{3n} = 0.$$

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_2] = \lim_{n \rightarrow \infty} \theta = \theta \text{ e } \lim_{n \rightarrow \infty} Var[\hat{\theta}_2] = \lim_{n \rightarrow \infty} \frac{\theta^2}{n+2} = 0.$$

Dessa forma, observamos que ambos os estimadores são consistentes, pois atendem às características estipuladas.

### Questão 5.

#### 1.

$X_i \sim Ber(\theta) \rightarrow E[X_i] = \theta; Var(X_i) = \theta(1-\theta)$ . Para  $\hat{\theta}_n$ , temos que  $E[\hat{\theta}_n] = E[\frac{1}{n} \sum_{i=1}^n X_i] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{n}{n} \theta = \theta$ .

Com isso, encontramos que  $\hat{\theta}_n$  é não viciado, pois:  $B(\hat{\theta}_n) = E[\hat{\theta}_n] - \theta = 0$ .

#### 2.

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \lim_{n \rightarrow \infty} \theta = \theta.$$

$$Var(\hat{\theta}_n) = Var(\frac{1}{n} \sum_{i=1}^n X_i) = \frac{n}{n^2} Var(X) = \frac{\theta(1-\theta)}{n} \rightarrow \lim_{n \rightarrow \infty} Var[\hat{\theta}_n] = \lim_{n \rightarrow \infty} \frac{\theta(1-\theta)}{n} = 0.$$

Portanto, observamos que o estimador  $\hat{\theta}_n$  é consistente, pois atende às características estipuladas.

#### 3.

Sendo  $X_n$  uma sequência de v.a's i.i.d. com distribuição  $Ber(\theta)$  e  $S_n = \sum_{i=1}^n X_i$ , de forma que  $E[S_n] = n\theta$  e  $Var(S_n) = n\theta(1-\theta)$  temos que, pelo teorema de Moivre-Laplace,  $\frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \sim N(0, 1)$ , ou, paralelamente,  $S_n \sim N(n\theta, n\theta(1-\theta))$ .

Agora, para  $\hat{\theta}_n$ , com parâmetros  $E[\hat{\theta}_n] = \theta$  e  $Var(\hat{\theta}_n) = \frac{\theta(1-\theta)}{n}$ , encontramos o seguinte:

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} = \frac{\frac{1}{n} S_n - \theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} \rightarrow \frac{\frac{1}{n} S_n - \theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} \cdot \frac{n}{n} = \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \sim N(0, 1).$$

Isso nos leva à  $\frac{\hat{\theta}_n - \theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} \sim N(0, 1) \rightarrow \hat{\theta}_n \sim N(\theta, \frac{\theta(1-\theta)}{n})$

4.

**Input:**

- Probabilidade de sucesso:  $\theta = 0.5$ ;
- Número de amostras:  $num\_amostras = 10000$ ;
- Vetor para conter as médias obtidas:  $seq\_medias$ .

**Código:**

- Gerar amostra de números aleatórios com distribuição Bernoulli( $\theta = 0.5$ );
- Armazenar cada uma das médias acumuladas dos valores gerados de 1 à  $num\_amostras$ ;
- Plotar as médias amostrais obtidas em função do tamanho da amostra.

**Output:**

- Gráfico apresentando as médias obtidas (tanto as acumuladas quanto a teórica);
- Valor esperado e valor simulado da média acumulada.

5.

**Input:**

- Probabilidade de sucesso:  $\theta = 0.5$ ;
- Número de amostras:  $num\_amostras = 10000$ ;
- Número de simulações a gerar:  $simulacoes = 10000$ .

**Código:**

- Obter a média e desvio padrão teóricos para  $\hat{\theta}_n \sim N(\theta, \frac{\theta(1-\theta)}{n})$ ;
- Gerar amostras de números aleatórios com distribuição Bernoulli( $\theta = 0.5$ );
- Armazenar as médias e desvios obtidos das simulações realizadas para  $\theta_n \sim N(\theta, \frac{\theta(1-\theta)}{n})$ ;
- Plotar as médias amostrais obtidas.

**Output:**

- Histograma apresentando as médias obtidas (tanto as simuladas quanto a teórica);
- Valores esperados e simulados da média e desvio padrão para  $\hat{\theta}_n \sim N(\theta, \frac{\theta(1-\theta)}{n})$ .

6.

```
# Parâmetros
theta <- 0.5

# Número de amostras a gerar
num_amostras <- 10000

# Vetor que irá conter as médias obtidas
```

```
seq_medias <- NULL

# Armazenar os números aleatórios gerados
set.seed(123)
y <- rbinom(num_amostras, size = 1, prob = theta)

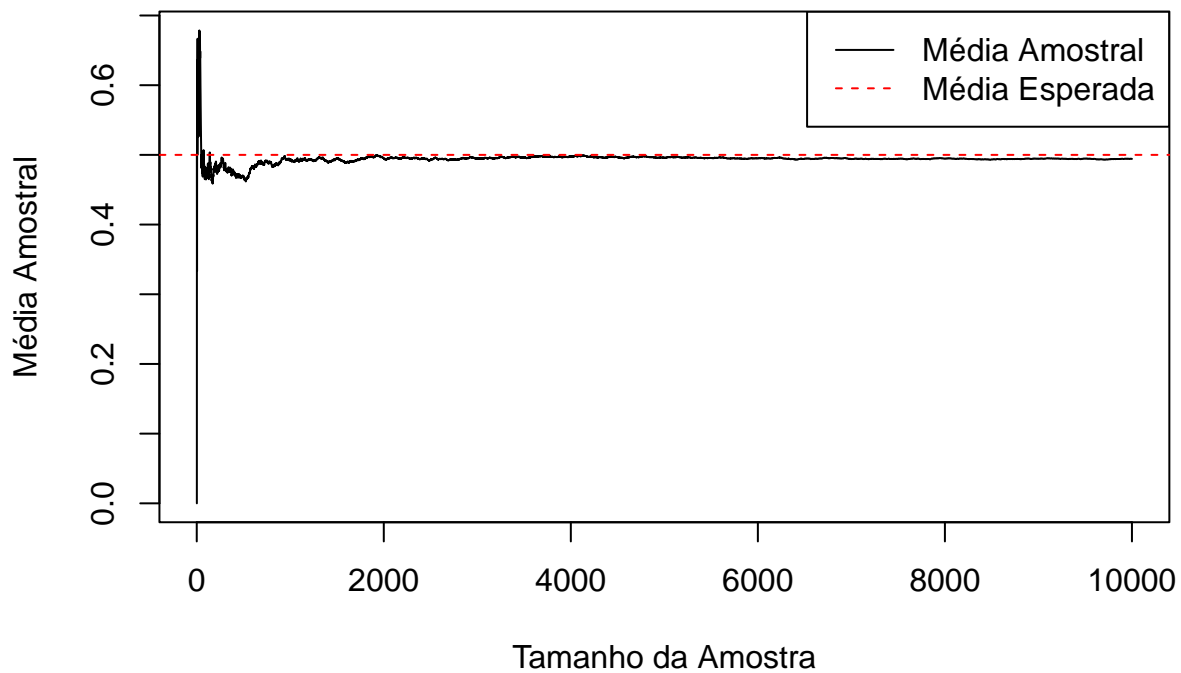
for (i in 1:num_amostras){
  seq_medias[i] <- mean(y[1:i])
}

# Plotar as médias amostrais em função do tamanho da amostra
plot(1:num_amostras, seq_medias, type = "l",
     main = "Lei dos Grandes Números para Bernoulli(0.5)",
     xlab = "Tamanho da Amostra", ylab = "Média Amostral")

abline(h = theta, col = "red", lty = 2)

legend("topright", legend = c("Média Amostral", "Média Esperada"),
       col = c("black", "red"), lty = c(1, 2))
```

## Lei dos Grandes Números para Bernoulli(0.5)



```
## [1] "Média esperada = 0.5"
```

```
## [1] "Média obtida = 0.4943"
```

7.

```
# Parâmetros
theta <- 0.5

# Número de amostras a gerar
num_amostras <- 10000

# Número de simulações
simulacoes <- 10000

# Valores teóricos para a Normal
media_esperada <- theta
desvio_esperado <- sqrt(theta * (1 - theta) / num_amostras)

tcl <- function(num_amostras, theta, simulacoes) {
  set.seed(123)
  seq_medias <- NULL
  for (i in 1:simulacoes) {
    amostra <- rbinom(num_amostras, size = 1, prob = theta)
    seq_medias[i] <- mean(amostra)}
  return(seq_medias)}
medias_simuladas <- tcl(num_amostras, theta, simulacoes)


hist(medias_simuladas, breaks = 30, probability = TRUE,
main = "Distribuição da Média Amostral",
xlab = "Média Amostral", col = "lightblue", border = "black",
ylab = "Densidade")

curve(dnorm(x, mean = media_esperada, sd = desvio_esperado),
col = "red", lwd = 2, add = TRUE)

abline(v = theta, col = "red", lty = 2)

legend("topright", legend = c("Média Amostral", "Média Esperada"),
col = c("black", "red"), lty = c(1, 2))
```

## Distribuição da Média Amostral



```
## [1] "Média esperada = 0.5"
```

```
## [1] "Média obtida = 0.49998524"
```

```
## [1] "Desvio esperado = 0.005"
```

```
## [1] "Desvio obtido = 0.00500558625255556"
```